

Trabalho Prático

Classificação da resposta ao tratamento do câncer de mama usando redes neurais

Valor: 35 pontos

Penalidade por atraso: Valor total, não se admite atraso!

Datas importantes:

- Cadastro dos grupos até 05/10/2026 nas planilhas:

Campus Coração Eucarístico:

https://docs.google.com/spreadsheets/d/13KB5RBTIDkkRt9an-vbLVvg3BaORwXKJFgJmDZ-P_ds/edit?usp=sharing

Campus Lourdes:

<https://docs.google.com/spreadsheets/d/11blwde891gWPDakHzWekodnFZbXZ7K4iDxzcpdkSfS0/edit?usp=sharing>

Após essa data a planilha será **fechada** e os grupos não poderão ser alterados. **Os alunos que não tiverem feito grupos até essa data deverão informar os grupos por email e perderão 5 pontos na atividade.**

- Entrega do trabalho

16/11/2026 até 19:00 pelo Canvas

Descrição:

A DCE-MRI (Ressonância Magnética Dinâmica Realçada por Contraste) é uma técnica avançada de imagem médica que consiste na aquisição rápida e repetida de imagens de ressonância magnética antes, durante e após a injeção intravenosa de um meio de contraste à base de gadolínio. Esse método permite monitorar, em tempo real, a passagem do contraste pelos tecidos do corpo humano, sendo amplamente utilizada para detectar e caracterizar tumores malignos como o câncer de mama quanto à sua agressividade e monitorar a resposta de pacientes a tratamentos oncológicos. Em pacientes com câncer de mama, o exame de DCE-MRI objetiva avaliar a predição da resposta patológica completa (pCR), ou seja, se a quimioterapia conseguirá eliminar todas as células tumorais invasivas antes da

cirurgia, de modo que o médico possa adaptar o tratamento e planejar cirurgias de forma mais individualizada.

A Fig. 1 mostra exemplos imagens obtidas por DCE-MRI em três momentos: antes, durante e após a administração do contraste em um paciente com câncer de mama.




Fig. 1. Exemplos de imagens de DCE-MRI em três momentos: (a) antes, (b) durante, e (c)

Fig. 1. Exemplos de imagens de DCE-MRI em três momentos: (a) antes, (b) durante, e (c)

Neste trabalho, você deverá desenvolver e avaliar um sistema baseado em redes neurais capaz de classificar pacientes com câncer de mama de acordo com a ocorrência ou não de resposta patológica completa (pCR) ao tratamento, utilizando exclusivamente informações obtidas das imagens DCE-MRI. O trabalho deverá investigar se a utilização conjunta das diferentes fases temporais da DCE-MRI contribui para a classificação. A hipótese a ser investigada é de que a utilização conjunta das informações temporais presentes nas imagens melhora a classificação da pCR quando comparada à utilização isolada de imagens de cada fase da aquisição.

Materiais:

O dataset BreastDCEDL [1] é um conjunto de dados publicado em 2026 com DCE-MRI de pacientes com câncer de mama, que inclui imagens, mapas de segmentações tumorais e informações clínicas. O subconjunto I-SPY1 MinCrop Version 4 contém dados de 172 pacientes nos três momentos temporais da aquisição: pré-contraste, pós-contraste precoce e pós-contraste tardio, em volumes de 256x256 voxels por plano, recortadas em torno do tumor. Para cada paciente, é disponibilizado um volume com a segmentação do tumor. O Dataset (BreastDCEDL_ISPY1_min_crop 1.3GB) está disponível em:

https://zenodo.org/records/18114231/files/BreastDCEDL_ISPY1_min_crop.tar.gz?download=1

Uma planilha no formato csv detalha qual a classe da imagem: pCR ausente (0) ou presente (1), número de planos, dados clínicos e demográficos, e informações sobre a partição do dataset em

treino, validação e teste. Mais informações podem ser encontradas no artigo original e material suplementar que acompanham o dataset, disponibilizados no Canvas.

Especificações do programa:

O ambiente deve ser totalmente gráfico e deverá oferecer as seguintes opções:

- a) Ler e visualizar imagens no formato nii. As imagens devem ser exibidas no plano xy , com possibilidade de navegar de um plano a outro na direção z . O volume de segmentação deve ser mostrado ao lado e acompanhar a seleção do corte z selecionado. Utilize um visualizador de imagens como o MRICro (<https://people.cas.sc.edu/rorden/mricro> ou <https://www.nitrc.org/projects/mricro>) para verificar se as imagens estão sendo exibidas de forma correta na sua interface.
- b) Realizar aumento de dados **das imagens de treino/validação** através de espelhamento e pequenas rotações entre -20 e 20 graus, em intervalos de 10 graus. Dessa forma, cada imagem deve gerar 10 variações (-20 , -10 , 0 , 10 , 20 graus) $\times$ (original e espelhada). Verifique se existe desbalanceamento entre as classes de pCR ausente e presente. Caso exista desbalanceamento relevante, proponha uma estratégia para seu tratamento, como: pesos diferentes para as classes na função de perda, aumento de dados proporcional, focal loss ou outra estratégia devidamente justificada.
- c) Uma vez que a DCE-MRI é tridimensional e as redes convolucionais 2D recebem imagens bidimensionais, deverão ser investigadas pelo menos 2 das seguintes estratégias para combinar as informações de diferentes cortes:
 - seleção do corte central de cada volume
 - seleção do corte contendo maior área tumoral
 - todos os cortes, tomando-se uma média das previsões
 - todos os cortes, tomando-se o máximo das previsões
 - outro modelo de agregação das previsões extraídas pelos diferentes cortes
- d) Implementar as seguintes soluções, que devem receber as imagens de DCE-MRI como entrada e fornecer na saída uma probabilidade de pertencimento à classe pCR:
 - Uma arquitetura CNN de no mínimo 5 camadas com parâmetros (camada de entrada e pooling não contam) para classificação binária das imagens. A arquitetura deve ser detalhada na documentação e a escolha dos hiperparâmetros justificada.
 - A Resnet50. Utilize os pesos disponíveis do modelo treinado com o ImageNet, retreinando a parte completamente conectada com o dataset de treino e fazendo as adaptações nas dimensões das camadas de entrada e saída. Após a convergência, salve o modelo com os pesos para não ter que retreinar na hora da apresentação.

- Uma nova solução baseada em rede neural profunda à escolha, combinações ou adaptações de quaisquer outros modelos. Após o treinamento, salve o modelo com os pesos para não ter que retreinar na hora da apresentação.

O treinamento e teste das 3 redes devem seguir 2 estratégias:

- Treinar os modelos utilizando somente uma das fases da DCE-MRI (pré-contraste, pós-contraste precoce ou pós-contraste tardio)
 - Treinar os modelos utilizando conjuntamente as três fases temporais. Uma possibilidade é representar as três fases como três canais de entrada (Canal 1: pré-contraste, Canal 2: pós-contraste precoce, Canal 3: pós-contraste tardio). Outra possibilidade é utilizar uma arquitetura com ramos independentes para cada fase e posteriormente combinar suas representações.
- e) Escolher uma imagem e classifica-la, mostrando o resultado na tela, bem como as regiões analisadas para a decisão da rede, usando a técnica de Grad-CAM.

Opcional: Adicionar na entrada a máscara de segmentação como outro canal ou aplicar a máscara na imagem, zerando os níveis de cinza do fundo. Comparar com os resultados sem segmentação.

Considerações gerais e critérios de avaliação

- a) O trabalho deverá ser feito em grupos de três ou quatro alunos, sem qualquer participação de outros grupos e/ou ajuda de terceiros. Cada aluno deve participar ativamente em todas as etapas do trabalho pois a avaliação é individual.
- b) É permitido o uso de funções elementares de bibliotecas mas o código principal deve ser original. Por função elementar entende-se uma função básica de manipulação de imagens, cujo resultado não seja a solução final do problema. Ex: leitura de arquivos, cálculo de histogramas, filtros, cálculo de distâncias, conversão entre formatos de imagens, cálculo de características, classificadores pré-treinados. Ao usar uma função de biblioteca, os hiperparâmetros escolhidos devem ser descritos e os valores usados justificados.
- c) O uso de IA e exemplos de implementação encontrados em repositórios deve ser direcionado ao aprendizado, não substituindo os alunos na execução do trabalho. Qualquer uso desses recursos deve ser **devidamente referenciado**. Um arquivo suplementar deverá ser enviado contendo uma declaração do uso de ferramentas de IAG, de qualquer espécie e em qualquer fase do desenvolvimento do trabalho (concepção, redação, análise de dados, codificação) especificando nos respectivos textos (prompts), as ferramentas utilizadas e a finalidade. Na dúvida, pergunte ao professor se o uso das ferramentas é permitido para uma determinada tarefa.
- d) A codificação do trabalho deve ser feita em linguagem Python em um arquivo único (não enviar

notebook jupyter). A apresentação poderá ser feita em um notebook levado pelo grupo ou em um computador do laboratório. Neste caso, não poderão ser utilizadas bibliotecas gráficas ou qualquer recurso que não esteja instalado oficialmente nos laboratórios do ICEI. O grupo que desejar apresentar no laboratório deve informar o professor com uma semana de antecedência.

- e) Todo arquivo enviado deve conter o nome, matrícula, curso e campus dos componentes do grupo.
- f) Os trabalhos (código-fonte Python, relatório com respectivas fontes em Latex e PDF final, declaração de uso de IAG) devem ser postados na forma de um arquivo compactado no padrão ZIP **por apenas um dos componentes**, com **tamanho máximo de 10 MB**, e seu nome deve ser o número do grupo fornecido pelo professor (Gnn) (Ex: G01.zip). **Não insira os datasets no arquivo. Os arquivos devem estar no diretório raiz** e devem conter o nome de todos os componentes do grupo no início do código. A apresentação será feita a partir do código postado no Canvas. **Trabalhos com mais de 10 MB não serão corrigidos.**
- g) **Trabalhos iguais, na sua totalidade ou em partes, gerados por IA ou copiados serão severamente penalizados. É responsabilidade do grupo manter o sigilo sobre seu trabalho, evitando que outros alunos tenham acesso a ele. No caso de cópia, ambos os trabalhos serão penalizados, independentemente de quem lesou ou foi lesado no processo.**
- h) Durante os dias de apresentação poderão ser feitas perguntas relativas ao trabalho e aplicada uma prova escrita, as quais serão consideradas para fim de avaliação. Todos os componentes devem comparecer e serem capazes de responder a **quaisquer perguntas e/ou alterar o código de qualquer parte do trabalho**. A avaliação será individual. Apenas os grupos que tiverem postado o trabalho poderão fazer prova escrita.
- i) A avaliação será baseada nos seguintes critérios:
 - Correção, robustez e eficiência dos programas quanto ao tempo de processamento e uso de memória
 - Conformidade às especificações
 - Clareza e estilo de codificação (comentários, indentação, escolha de nomes para identificadores, parametrização)
 - Relatório
 - Avaliação individual

ATENÇÃO - Causas da anulação da nota do trabalho:

- Alunos que não se cadastrarem;
- Alunos que não comparecerem à apresentação;
- Trabalhos entregues fora do prazo;
- Trabalhos copiados de qualquer fonte, reaproveitados de outros semestres, em parte ou totalidade, ou gerados por Inteligência Artificial. É responsabilidade do grupo manter o sigilo sobre seu trabalho. O trabalho deve ser realizado exclusivamente pelos componentes do

grupo, sem auxílio de terceiros. No caso de uso do GitHub, deixe o repositório em modo privado.

- Ausência de documentação
- Arquivos maiores que o limite de tamanho e documentação maior que o número de páginas máximo.
- Trabalhos postados por mais de um componente ou com número de grupo errado perdem 5 pontos.

Documentação

Documente as soluções e os testes, na forma de um relatório técnico em formato Latex e PDF com no máximo 12 páginas, segundo o padrão da SBC, contendo as seguintes seções:

- a) Introdução: Descrever o problema e o objetivo do trabalho.
- b) Descrição dos datasets e das técnicas implementadas para a solução, principalmente dos classificadores.
- c) Descrever as bibliotecas utilizadas, suas principais funções e seus hiperparâmetros de forma clara.
- d) Resultados obtidos nos testes segundo as métricas de sensibilidade, especificidade, precisão, acurácia e escore F1, gráficos de convergência da Loss, exemplos de erros e acertos dos métodos. Informar também as medidas de tempo de treinamento.
- e) Discussão dos resultados obtidos nos classificadores, justificativa e análise de todos os hiperparâmetros e estratégias usados na concepção do classificador, incluindo o controle de overfitting, underfitting e velocidade de convergência. Incluir uma figura com a topologia da rede e uma comparação de resultados intermediários obtidos no processo de ajuste de hiperparâmetros. A nota será proporcional ao esforço empenhado no ajuste e qualidade da análise.
- f) Referências bibliográficas.

O relatório deverá responder, entre outras, às seguintes perguntas:

- A utilização das três fases temporais produz resultados melhores do que a utilização de uma única fase?
- Qual modelo de rede apresentou melhor desempenho?
- Quais tipos de erros são mais frequentes?
- As regiões destacadas pelo Grad-CAM estão relacionadas às regiões tumorais?
- Quais são as principais limitações da abordagem desenvolvida?

O que entregar:

Arquivos fontes, documentação e declaração do uso de IAG. Coloque todos os arquivos na raiz de um diretório cujo nome deve ser o número de matrícula de um dos componentes. Comprima o diretório e

poste no Canvas até a hora especificada para cada parte. O tamanho total dos arquivos não deve ultrapassar 10 Mbytes (não envie dataset nem o arquivo de pesos!).

Obs: Trabalhos de qualidade superior poderão ganhar pontos extras assim como o que obtiver as maiores taxas de acerto no CONJUNTO-TESTE SURPRESA!

Referências

[1] Fridman, Naomi, et al. "BreastDCEDL: A standardized deep learning-ready breast DCE-MRI dataset of 2,070 patients." *Scientific Data* 13.1 (2026): 264.